

e statistique.
a série statistique

série statistique.
on en fonction du
ion. On observe
(200) est partagé
ctère étudié). La

tifs des classes
96
60
30
8

statistique.

le en supposant

nt d'asymétrie

On désigne par
rie statistique.

nombre x de
obtenus sont

ue.


er quartile, le

[c] Calculer le moment centré d'ordre 3 puis le coefficient de dérive. Que peut-on en conclure en ce qui concerne la symétrie de la distribution ?

[les solutions]

[2.2.1] [a] Tableau des fréquences

nombre n de bourgeons par tige	2	3	4	5	6	7	8	9	10	11	12
fréquences absolues	3	5	10	15	23	19	13	5	3	3	1
fréquences relatives cumulées	0,03	0,08	0,18	0,33	0,56	0,75	0,88	0,93	0,96	0,99	1




[b] Fonction de répartition

Soit $\{x'_j, 1 \leq j \leq 11\}$ les valeurs de la série statistique ; ces valeurs sont :

2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12.

La fonction de répartition F est définie par (§ 2.2.2)† :

$F(x) = 0$ si $x < 2$, $F(x) = 1$ si $x \geq 12$ et $F(x)$ est la fréquence relative cumulée des valeurs de la série statistique inférieure à x'_{j+1} si $x \in [x'_j, x'_{j+1}[$, $1 \leq j \leq 11$.




[2.2.2] [a] Tableau des fréquences

nombre n d'enfants par famille	0	1	2	3	4	5	6	7	8
fréquences absolues ou nombre de familles ayant n enfants	91	146	104	63	47	33	10	4	2
fréquences relatives cumulées	0,182	0,474	0,682	0,808	0,902	0,968	0,988	0,996	1


† Voir la note au bas de la page 15.

umulée des



[b] Fonction de répartition

La définition est celle donnée dans l'exercice [2.2.1] avec ici $p = 9$.



[c] Nombre moyen d'enfants par famille dans l'échantillon.

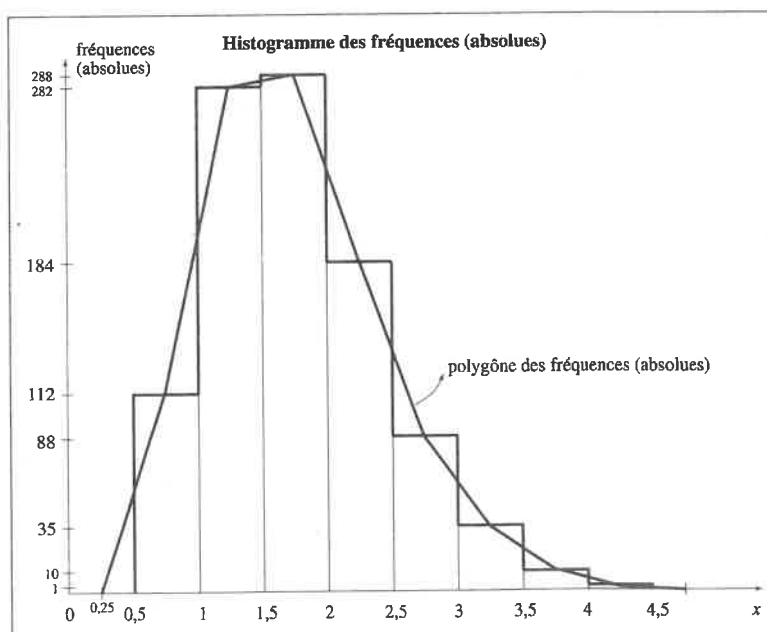
Soit m ce nombre ; alors on a :


$$m = \frac{1}{500} (0 \times 91 + 1 \times 146 + 2 \times 104 + 3 \times 63 + 4 \times 47 + 5 \times 33 + 6 \times 10 + 7 \times 4 + 8 \times 2) = \frac{1\,000}{500} = 2.$$

[2.2.3] [a] Centres des classes et fréquences cumulées

x	centres des classes	fréquences absolues	fréquences absolues cumulées	fréquences relatives cumulées
$0,5 \leq x < 1$	0,75	112	112	0,112
$1 \leq x < 1,5$	1,25	282	394	0,394
$1,5 \leq x < 2$	1,75	288	682	0,682
$2 \leq x < 2,5$	2,25	184	866	0,866
$2,5 \leq x < 3$	2,75	88	954	0,954
$3 \leq x < 3,5$	3,25	35	989	0,989
$3,5 \leq x < 4$	3,75	10	999	0,999
$4 \leq x < 4,5$	4,25	1	1 000	1

[b]






[c] L'histogramme des fréquences (absolues) nous conduit à supposer que X pourrait suivre une loi du χ^2 .

[2.2.4] [a] L'étendue commune des classes est la distances des centres de deux classes consécutives, soit 0,4. Les extrémités des classes sont donc :

5,4 – 5,8 ; 5,8 – 6,2 ; 6,2 – 6,6 ; 6,6 – 7,0 ; 7,0 – 7,4 ; 7,4 – 7,8 ; 7,8 – 8,2 ; 8,2 – 8,6 ; 8,6 – 9,0.



[c] L'histogramme des fréquences (absolues) nous conduit à supposer que la variable aléatoire « diamètre des hématies » pourrait suivre une loi de Gauss.

[2.3.5]

$$\sum_{i=1}^n (x_i - \alpha)^2 = \sum_{i=1}^n (x_i - m + m - \alpha)^2 = \sum_{i=1}^n (x_i - m)^2 + 2(m - \alpha) \sum_{i=1}^n (x_i - m) + n(m - \alpha)^2.$$

Or :

$$\sum_{i=1}^n (x_i - m) = \sum_{i=1}^n x_i - nm = nm - nm = 0.$$

Donc :

$$\sum_{i=1}^n (x_i - \alpha)^2 = \sum_{i=1}^n (x_i - m)^2 + n(m - \alpha)^2 \geq \sum_{i=1}^n (x_i - m)^2,$$

et l'égalité a lieu si et seulement si $\alpha = m$ et la valeur minimum de cette somme est $\sum_{i=1}^n (x_i - m)^2 = n\sigma^2$ où σ désigne l'écart type de la série statistique.

[2.3.6] Quitte à renuméroter les valeurs de la série statistique, on peut supposer que les valeurs x_i sont rangées par ordre de valeurs non décroissantes :

$$x_1 \leq x_2 \leq \dots \leq x_{n-1} \leq x_n.$$

Rappelons que l'écart absolu de α à un nombre x est $|x - \alpha|$. Soit a et b tels que $a \leq b$; la somme des écarts absolus de α à a et b est $e = |a - \alpha| + |b - \alpha|$.

- Si $a \leq \alpha \leq b$, $e = (\alpha - a) + (b - \alpha)$ et ce résultat est indépendant de α .
- Si $\alpha \leq a \leq b$, $e = (a - \alpha) + (b - \alpha) = b - a + 2(a - \alpha) \geq b - a$.
- Si $a \leq b \leq \alpha$, $e = (\alpha - a) + (\alpha - b) = b - a + 2(\alpha - b) \geq b - a$.

Ainsi la somme des écarts absolus de α à a et b est minimum quand α est (quelconque) entre a et b .

Appliquons ce résultat à la série statistique.

- La somme des écarts absolus de α à x_1 et x_n est minimum lorsque α est quelconque entre x_1 et x_n .
- De même si α est aussi quelconque entre x_2 et x_{n-1} , la somme des écarts absolus de α à x_2 et x_{n-1} sera minimum.

Il en sera aussi de même pour x_3 et x_{n-2} et ainsi de suite.

On veut donc que la somme des écarts absolus de α aux valeurs x_i de la série statistique sera minimum lorsque le nombre de valeurs de la série statistique supérieures à α sera égal au nombre de valeurs de la série statistique inférieures à α ; c'est-à-dire lorsque α est la médiane.

[2.3.7] Les valeurs sont ordonnées par ordre de valeurs non décroissantes :

1 2 2 3 4 4 5 6 7 7 8 9 10 11 12.

Il y a $n = 15 = 2p + 1$ valeurs où $p = 7$.

[a] Mode

Il y a trois valeurs modales 2, 4 et 7 de fréquence absolue 2.

[b] Médiane

C'est la valeur de la suite située au rang $p + 1 = 8$, soit la valeur 6.

[c] Moyenne

$$\begin{aligned} m &= \frac{1}{15} (1 + 2 + 2 + 3 + 4 + 4 + 5 + 6 + 7 + 7 + 8 + 9 + 10 + 11 + 12) \\ &= \frac{91}{15} \simeq 6,07. \end{aligned}$$

[d] Écart type σ

Soit m_2 le moment d'ordre 2 :

$$\begin{aligned} m_2 &= \frac{1}{15} (1^2 + 2 \times 2^2 + 3^2 + 2 \times 4^2 + 5^2 + 6^2 + 2 \times 7^2 \\ &\quad + 8^2 + 9^2 + 10^2 + 11^2 + 12^2) \\ &= \frac{719}{15}. \end{aligned}$$

On a alors (voir [Théorème 2.3.3]) :

$$\begin{aligned} \sigma^2 &= \mu_2 = m_2 - m^2 = \frac{719}{15} - \left(\frac{91}{15}\right)^2 = \frac{10\,785 - 8\,281}{225} \\ &= \frac{2\,504}{225} = 11,128\,8\dots \\ \sigma &\simeq 3,34. \end{aligned}$$

[e] Premier quartile Q_1 et troisième quartile Q_3

Q_1 est la médiane de la suite de valeurs :

1 2 2 3 4 4 5,

donc $Q_1 = 3$.

Q_3 est la médiane de la suite de valeurs :

7 7 8 9 10 11 12,

donc $Q_3 = 9$.

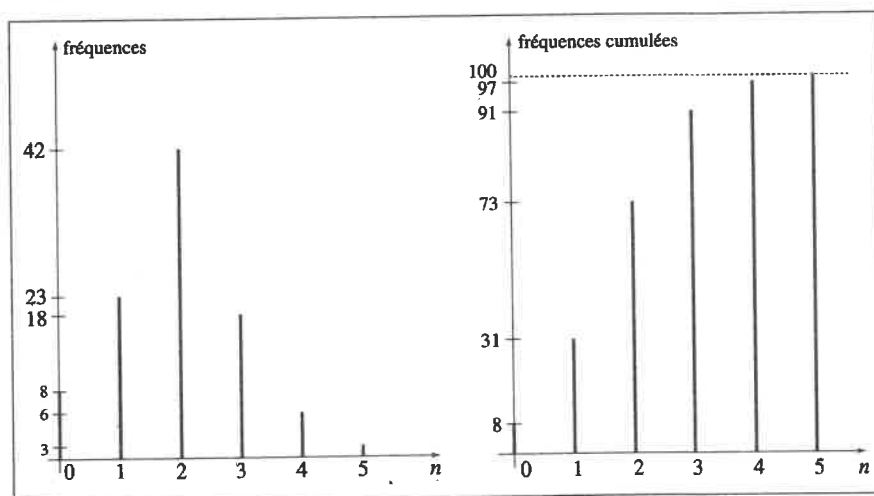
[f] Le semi-interquartile Q est ([Définition 2.3.3]) :

$$Q = \frac{1}{2} (Q_3 - Q_1) = \frac{1}{2} (9 - 3) = 3.$$

[2.3.8] [a] [i] Tableau de fréquences


nombre n d'enfants	0	1	2	3	4	5
fréquences absolues ou nombre de familles ayant n garçons	8	23	42	18	6	3
fréquences absolues cumulées	8	31	73	91	97	100

[ii] Diagrammes en bâtons des fréquences et des fréquences cumulées



[b] • Le mode est la valeur de plus grande fréquence ; c'est donc 2 (fréquence 42).

• Il y a deux valeurs en centre, ce sont les valeurs placées au rang 50 et au rang 51. Ces deux valeurs sont égales à 2 donc la médiane est 2.



• La moyenne m est :

$$m = \frac{1}{100} (0 \times 8 + 1 \times 23 + 2 \times 42 + 3 \times 18 + 4 \times 6 + 5 \times 3) = \frac{200}{100} = 2.$$

[c] • Le premier quartile Q_1 est tel que 25 % des valeurs de la série statistique lui soit inférieur, donc $Q_1 = 1$.

• Le premier quartile Q_3 est tel que 75 % des valeurs de la série statistique lui soit inférieur, donc $Q_3 = 3$.

• Soit m_2 le moment d'ordre 2 :

$$m_2 = \frac{1}{100} (0^2 \times 8 + 1^2 \times 23 + 2^2 \times 42 + 3^2 \times 18 + 4^2 \times 6 + 5^2 \times 3) = \frac{524}{100} = 5,24.$$

La variance est donc :

$$v = m_2 - m^2 = 5,24 - 4 = 1,24.$$


D'où l'écart type :

$$\sigma = \sqrt{1,24} \simeq 1,11.$$

[2.3.9] [a] [i] Tableau des fréquences

nombre n de garçons	0	1	2	3	4	5	6	7	8
fréquences absolues ou nombre de familles ayant n garçons	48	295	1 425	2 213	3 438	2 457	1 607	453	64
fréquences absolues cumulées	48	343	1 768	3 981	7 419	9 876	11 483	11 936	12 000

[i] Diagramme en bâtons des fréquences (absolues)



[b] • La valeur de plus grande fréquence est 4, donc le mode est 4.

• Le nombre de familles est $n = 12\,000 = 2 \times 6\,000$; par conséquent, il y a deux valeurs situées au centre de la série statistique, ce sont les valeurs placées aux rang 6 000 et 6 001. Il en résulte que la médiane est 4.

• La moyenne m est :

$$m = \frac{1}{12\,000} [0 \times 48 + 1 \times 295 + 2 \times 1\,425 + 3 \times 2\,215 + 4 \times 3\,438 \\ + 5 \times 2\,457 + 6 \times 1\,607 + 7 \times 453 + 8 \times 64]$$
$$m = \frac{49\,146}{12\,000} = 4,0955.$$

[c] Soit m_2 le moment d'ordre 2 :

$$m_2 = \frac{1}{12\,000} [0^2 \times 48 + 1^2 \times 295 + 2^2 \times 1\,425 + 3^2 \times 2\,215 + 4^2 \times 3\,438 \\ + 5^2 \times 2\,457 + 6^2 \times 1\,607 + 7^2 \times 453 + 8^2 \times 64]$$
$$m_2 = \frac{226\,490}{12\,000}.$$

La variance v est :

$$v = m_2 - m^2 = \frac{226\,490 \times 12\,000 - (49\,146)^2}{(12\,000)^2} = 2,101\,04 \dots$$

d'où l'écart type :

$$\sigma = \sqrt{v} \simeq 1,45.$$

[2.3.10] [a] [i] Médiane

Il y a $n = 1\,000$ observations, donc la médiane appartient à la classe de centre 7,2 et d'extrémités 7 et 7,4.

On calcule la médiane M par interpolation linéaire (§ **[3][A][b]**) :

$$M = 7 + \frac{500 - 355}{270} \times 0,4 = 7,2148 \dots \simeq 7,215.$$

[ii] Moyenne m

$$m = \frac{7\,250}{1\,000} = 7,25.$$

[b] [i] Quartile et semi-interquartile

Le premier quartile Q_1 appartient à la classe de centre 6,8 et d'extrémités 6,6 et 7. On calcule Q_1 par interpolation linéaire (§ **[3][B][b]**) :

$$Q_1 = 6,6 + \frac{250 - 115}{240} \times 0,4 = 6,825.$$

Le troisième quartile Q_3 appartient à la classe de centre 7,6 et d'extrémités 7,4 et 7,8. Par interpolation linéaire, on a :

$$Q_3 = 7,4 + \frac{750 - 625}{175} \times 0,4 = 7,6857 \dots \simeq 7,686.$$

Le semi-interquartile est :

$$Q = \frac{1}{2}(Q_3 - Q_1) \simeq 0,4305.$$

Écart moyen

$$e_m = \frac{1}{1000} [5 \times 1,65 + 40 \times 1,25 + 70 \times 0,85 + 240 \times 0,45 + 270 \times 0,05 \\ + 175 \times 0,35 + 140 \times 0,75 + 50 \times 1,15 + 10 \times 1,55] \\ e_m = \frac{478,5}{1000} = 0,4785.$$

Écart type

Le moment d'ordre 2 est :

$$m_2 = \frac{1}{1000} [5 \times (5,6)^2 + 40 \times (6,0)^2 + 70 \times (6,4)^2 + 240 \times (6,8)^2 + 270 \times (7,2)^2 \\ + 175 \times (7,6)^2 + 140 \times (8,0)^2 + 50 \times (8,4)^2 + 10 \times (8,8)^2] \\ m_2 = \frac{52928,8}{1000} = 52,9288.$$

La variance est donc :

$$v = m_2 - m^2 = 52,9288 - 52,5265 = 0,3663.$$

D'où l'écart type :

$$\sigma = \sqrt{v} = 0,6052 \dots \simeq 0,605.$$

[2.3.11] Ordonnons la suite des mesures par ordre de valeurs non décroissantes :

15,86 15,88 15,88 15,88 15,88 15,91 15,91
15,91 15,93 15,95 15,96 15,96 16,01 19,81.

[a] Étendue de la série statistique (§ **[2][c]**) :

$$E = 19,81 - 15,86 = 3,95.$$

La valeur suspecte (valeur aberrante) : 19,81. En supprimant cette valeur, la nouvelle série est donc :

15,86 15,88 15,88 15,88 15,88 15,91 15,91
15,91 15,93 15,95 15,96 15,96 16,01,

et l'étendue de celle-ci est donc :

$$E' = 16,01 - 15,86 = 0,15.$$

[b] Moyenne m et écart type σ de la nouvelle série :

$$m = 15,9169 \dots \simeq 15,92$$

$$\sigma = 0,0415 \dots \simeq 0,042.$$

[c]

$$m - 2\sigma = 15,8337 \dots \simeq 15,83$$

$$m + 2\sigma = 16,000 \dots \simeq 16,00.$$

Toutes les valeurs de la nouvelle série statistique sauf la dernière valeur, c'est-à-dire 16,01, sont dans l'intervalle $[m - 2\sigma, m + 2\sigma]$.

On élimine la valeur 16,01 et on considère alors la série de mesures :


15,86 15,88 15,88 15,88 15,88 15,91

15,91 15,91 15,93 15,95 15,96 15,96.

D'où le poids atomique :

$$15,9091 \simeq 15,91.$$

[2.3.12] [a] Histogramme des fréquences (absolues)



[b] La classe de plus grande fréquence ou classe modale est la classe de centre 90 et d'extrémités 84 et 96.

Moyenne

$$m = \frac{1}{270} [9 \times 66 + 45 \times 78 + 75 \times 90 + 71 \times 102 + 37 \times 114 + 22 \times 126 + 8 \times 138 + 2 \times 150 + 1 \times 162]$$

$$m = \frac{26\,652}{270} \simeq 98,71.$$

Écart type

$$m_2 = \frac{1}{270} [9 \times (66)^2 + 45 \times (78)^2 + 75 \times (90)^2 + 71 \times (102)^2 + 37 \times (114)^2 + 22 \times (126)^2 + 8 \times (138)^2 + 2 \times (150)^2 + 1 \times (162)^2]$$

$$m_2 = \frac{2\,712\,888}{270} \simeq 10\,047,73.$$

La variance est donc[†] :

$$v = m_2 - m^2 = 303,8498 \dots$$

D'où l'écart type :

$$\sigma = \sqrt{v} \simeq 17,43.$$

[c] [i] Médiane

La médiane M est dans la classe de centre 102, d'extrémités 96 et 108 puisque la fréquence cumulée de cette classe est 200 ($\frac{n}{2} = 135$) ; M est déterminée par interpolation linéaire (§ 3)[a][b]) :

$$M = 96 + \frac{135 - 129}{71} \times 12 \simeq 97,014.$$

[ii] Les quartiles Q_1 et Q_3

Q_1 est dans la classe de centre 90 et d'extrémités 84 et 96, d'où :

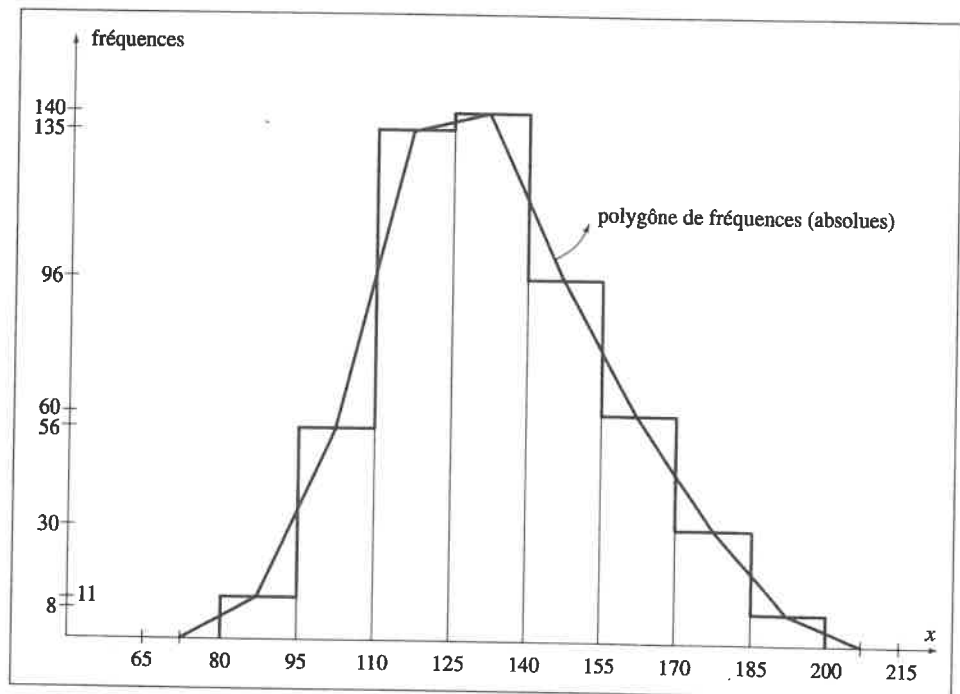
$$Q_1 = 84 + \frac{67,5 - 54}{75} \times 12 = 86,16.$$

Q_3 est dans la classe de centre 114 et d'extrémités 108 et 120, d'où :

$$Q_3 = 108 + \frac{202,5 - 200}{37} \times 12 \simeq 108,81.$$

[†] Pour calculer v , on écrit $m_2 - m^2$ sous forme fractionnaire et ensuite on fait l'approximation de σ .

[2.3.13] [a] Histogramme et polynôme des fréquences (absolues)



[b] Tableau indiquant les centres, les fréquences et les fréquences cumulées des classes.

centres	87,5	102,5	117,5	132,5	147,5	162,5	177,5	192,5
fréquences	11	56	135	140	96	60	30	8
fréquences cumulées	11	67	202	342	438	498	528	536

[c] La classe de plus grande fréquence ou classe modale est la classe de centre 132,5. Les limites de cette classe modale sont 125 et 140.

Médiane

L'effectif total est $n = 536$, or $\frac{n}{2} = 268$, par conséquent la médiane M appartient à la classe modale. On détermine M par interpolation linéaire (§ [3][a][b]) :

$$M = 125 + \frac{268 - 202}{140} \times 15 \simeq 132,07.$$

[c] Moyenne

Soit m la moyenne de la série statistique (connue par un partage en classes) :

$$m = \frac{1}{536} [11 \times 87,5 + 56 \times 102,5 + 135 \times 117,5 + 140 \times 132,5 \\ + 96 \times 147,5 + 60 \times 162,5 + 30 \times 177,5 + 8 \times 192,5] \\ m = \frac{71\,890}{536} \simeq 134,12.$$

Écart type

$$m_2 = \frac{1}{536} [11 \times (87,5)^2 + 56 \times (102,5)^2 + 135 \times (117,5)^2 + 140 \times (132,5)^2 \\ + 96 \times (147,5)^2 + 60 \times (162,5)^2 + 30 \times (177,5)^2 + 8 \times (192,5)^2] \\ m_2 = \frac{9\,908\,900}{536} \simeq 18\,486,75.$$

La variance est :

$$v = m_2 - m^2 = \frac{142\,998\,300}{(536)^2} \simeq 497,74.$$

D'où l'écart type :

$$\sigma = \sqrt{v} \simeq 22,31.$$

Coefficient de dérive

Le coefficient de dérive (ou coefficient d'asymétrie de Fisher) est défini par (§ 3)[C][b]) :

$$d = \frac{\mu_3}{\sigma^3},$$

où μ_3 est le moment centré d'ordre 3.

On trouve :

$$\mu_3 = \frac{2\,134\,360,263}{536} = 3\,982,015\,416.$$

D'où :

$$d = \frac{\mu_3}{\sigma^3} \simeq 0,36.$$

[Remarque] Le polygone des fréquences montre une assez bonne symétrie de la distribution expérimentale. Le coefficient $d \simeq 0,36$ indique que l'ensemble des valeurs de la série statistique est légèrement plus étalé du côté des valeurs supérieures à la moyenne. On notera aussi que la moyenne et la médiane appartiennent à la même classe qui est la classe modale.

[2.3.14] On sait que (§ [3][C][a]) :

$$m_q = \frac{1}{n} \sum_{i=1}^n x_i^q$$

$$\mu_q = \frac{1}{n} \sum_{i=1}^n (x_i - m)^q, \quad q \in \mathbb{N}^*,$$

où m désigne la moyenne de la série statistique.

Pour $q = 0$, la formule est évidente. Supposons q entier ≥ 1 . On a :

$$(x_i - m)^q = \sum_{k=0}^q (-1)^k \frac{q!}{k!(q-k)!} x_i^{q-k} m^k$$

$$\mu_q = \frac{1}{n} \sum_{i=1}^n \left(\sum_{k=0}^q (-1)^k \frac{q!}{k!(q-k)!} x_i^{q-k} m^k \right)$$

Et en échangeant les signes de sommation :

$$\mu_q = \frac{1}{n} \sum_{k=0}^q \left((-1)^k \frac{q!}{k!(q-k)!} m^k \sum_{i=1}^n x_i^{q-k} \right)$$


$$\mu_q = \sum_{k=0}^q \left((-1)^k \frac{q!}{k!(q-k)!} m_1^k \frac{1}{n} \sum_{i=1}^n x_i^{q-k} \right), \quad \text{car } m_1 = m.$$

D'où :

$$\mu_q = \sum_{k=0}^q (-1)^k \frac{q!}{k!(q-k)!} m_1^k m_{q-k}, \quad \forall q \in \mathbb{N}^*.$$

e la distri-
leurs de la
oyenne.
qui est la

[2.3.15] [a] Diagramme en bâtons des fréquence (absolues) de la série statistique



[b] [i] Valeur modale

La valeur de plus grande fréquence ou valeur modale est 4.

[ii] Moyenne m

$$m = \frac{1}{256} [0 \times 1 + 1 \times 9 + 2 \times 26 + 3 \times 59 + 4 \times 72 + 5 \times 52 + 6 \times 29 + 7 \times 7 + 8 \times 1]$$

$$m = \frac{1017}{256} \simeq 3,97.$$